MAKALAH LOMBA ANALISIS BIG DATA
FESTIVAL MAHASISWA ELEKTRO DAN INFORMATIKA
(FESMARO)

STRATEGI PREDIKSI PERMINTAAN CERDAS MENGHADAPI DISCONTINUED PRODUCT:
PENERAPAN TUNED XGBOOST PADA DATA SMART SUPPLY CHAIN

Disusun oleh:

1. Anindya Samantha Prayoga
2. Muhammad Firdig Haqqy Abdillah
3. Muhammad Wildan Nabila

UNIVERSITAS MUHAMMADIYAH MALANG

FAKULTAS TEKNIK

PROGRAM STUDI INFORMATIKA

2025

DAFTAR ISI

Abstrak 3
1. Pendahuluan 3
1.1 Latar Belakang 3
1.2 Rumusan Masalah 3
1.3 Tujuan Penelitian 3
1.4 Manfaat Penelitian 3
2. Tinjauan Pustaka 4
2.1 Big Data dan Prediksi Permintaan 4
2.2 Algoritma XGBoost 4
2.3 Studi Terkait 4
3. Metodologi 4
3.1 Langkah-Langkah Pengerjaan 4
3.2 Alat dan Teknologi 5
3.3 Sumber Data 6
3.4 Diagram Alur Proses 6
4. Analisis Hasil dan Visualisasi 6
4.1 Perbandingan MAPE Model 6
4.2 Visualisasi Bar 7
4.3 Interpretasi Model 9
5. Insight Strategis 9
6. Potensial Implementasi 9
7. Kesimpulan 10
Daftar Pustaka 11

Abstrak

Discontinued product merupakan salah satu penyebab utama ketidakseimbangan rantai pasok, yang berdampak pada kelebihan stok, kehilangan peluang penjualan, dan inefisiensi distribusi. Penelitian ini bertujuan untuk mengembangkan model prediksi permintaan berbasis machine learning yang mampu mengantisipasi dampak dari discontinued product secara proaktif. Dengan studi kasus pada dataset dari DataCo Smart Supply Chain, proses dimulai dengan eksplorasi data, preprocessing, dan feature engineering, lalu dilanjutkan pemodelan menggunakan berbagai algoritma regresi dan time series. Hasil menunjukkan bahwa model Tuned XGBoost menghasilkan performa terbaik dengan nilai MAPE 0.45%. Selain memberikan prediksi yang akurat, model ini juga menghasilkan insight strategis, seperti pentingnya fitur discount, late_delivery_risk, dan product_id terhadap pola permintaan. Temuan ini menunjukkan bahwa pendekatan machine learning tidak hanya mampu memberikan estimasi demand yang presisi, tetapi juga meningkatkan ketahanan rantai pasok dalam menghadapi disrupsi akibat produk yang dihentikan.

1. Pendahuluan

1.1 Latar Belakang

Dalam lingkungan bisnis yang kompetitif, keakuratan prediksi permintaan menjadi faktor kunci dalam menjaga efisiensi rantai pasok. Salah satu tantangan besar adalah ketika produk unggulan mengalami discontinued (penghentian produksi secara tiba-tiba), yang dapat memicu penurunan drastis dalam permintaan total. Menurut laporan McKinsey (2020), perusahaan yang menerapkan prediksi permintaan berbasis data secara efektif dapat meningkatkan efisiensi operasional hingga 20% dan mengurangi ketidaksesuaian stok hingga 30%.

1.2 Rumusan Masalah

Bagaimana membangun model prediktif berbasis machine learning untuk mengantisipasi perubahan permintaan secara drastis akibat produk yang dihentikan?

1.3 Tujuan Penelitian

Menentukan model terbaik untuk memprediksi permintaan bulanan dan memahami faktor-faktor yang paling berpengaruh terhadap perubahan demand.

1.4 Manfaat Penelitian

- Secara akademik:

Memberikan kontribusi dalam pengembangan penerapan XGBoost untuk time series forecasting.

- Secara praktis:
  Membantu perusahaan mengantisipasi risiko kehilangan demand dan merancang strategi mitigasi stok.

2. Tinjauan Pustaka

2.1 Big Data dan Prediksi Permintaan

Big Data telah menjadi pendorong utama dalam pengambilan keputusan bisnis modern, khususnya dalam sektor logistik dan supply chain. Teknik prediksi permintaan berbasis data memungkinkan perusahaan mengantisipasi perubahan pasar, mengoptimalkan inventaris, dan meningkatkan efisiensi distribusi (Zhang et al., 1998).

2.2 Algoritma XGBoost

XGBoost (Extreme Gradient Boosting) dikenal sebagai salah satu algoritma dengan performa tinggi. Menurut Chen & Guestrin (2016), XGBoost memiliki keunggulan dalam hal efisiensi komputasi dan akurasi prediksi, serta mendukung interpretasi variabel penting melalui feature importance.

2.3 Studi Terkait

Studi dari Chickowski (2019) menunjukkan bahwa implementasi machine learning dalam rantai pasok mampu mengoptimalkan proses pengadaan dan perencanaan permintaan, serta mempercepat respons terhadap perubahan pasar.

3. Metodologi

3.1 Langkah-Langkah Pengerjaan

3.1.1 Eksplorasi dan Pemahaman Data

- Mengamati pola permintaan bulanan, outlier, dan anomali.
- Teridentifikasi penurunan besar pada Oktober 2017, bersumber dari produk utama.

3.1.2 Preprocessing

- Penanganan nilai kosong dan encoding fitur kategorikal.

- Data diagregasi ke skala bulanan untuk analisis time series.

3.1.3 Feature Engineering

- Penambahan fitur seperti late_delivery_risk, profit_ratio, dan is_discontinued.
- Evaluasi korelasi fitur menggunakan heatmap untuk menghindari multikolinearitas.

3.1.4 Pemodelan

- Model diuji:
  - SARIMA
  - Holt-Winters
  - Linear
  - Ridge
  - Lasso
  - Random Forest
  - Gradient Boosting
  - XGBoost
  - Tuned XGBoost
  - Hybrid Model.
- Evaluasi menggunakan MAPE (Mean Absolute Percentage Error).

3.1.5 Evaluasi dan Interpretasi

- Visualisasi prediksi vs aktual.
- Analisis feature importance pada model XGBoost.

3.2 Alat dan Teknologi

- Bahasa pemrograman yang digunakan adalah Python
- Library:
  - Pandas
  - Scikit-learn
  - XGBoost
  - Statsmodels
  - Matplotlib
  - Seaborn
- Platform yang digunakan adalah Visual Studio Code

3.3 Sumber Data

- Dataset resmi dari penyelenggara: DataCo Smart Supply Chain
- Tidak menggunakan data eksternal tambahan

3.4 Diagram Alur Proses

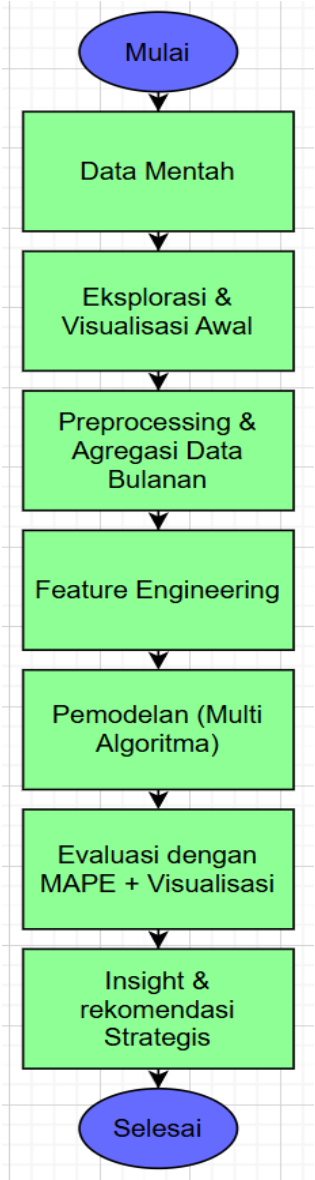

Gambar 1. Diagram Pipeline Proses Analitik

4. Analisis Hasil dan Visualisasi

4.1 Perbandingan MAPE Model

Tabel 1. Perbandingan MAPE Antar Model

No	Model	Mape (%)
1	Turned XGBoost	0.45

2	Random Forest	0.48
3	Hybird	0.51
4	XGBoost	0.47
5	Gradient Boosting	0.62
6	Ridge Regression	0.78
7	Lasso Regression	0.89
8	Linear Regression	0.75
9	Holt-Winters	2.59
10	SARIMA	2.62

4.2 Visualisasi Bar

a. Chart MAPE Model:

Gambar ini menunjukkan perbandingan MAPE (Mean Absolute Percentage Error) antar berbagai model prediksi. MAPE adalah metrik yang menunjukkan seberapa besar kesalahan rata-rata model dalam bentuk persentase semakin kecil nilainya, semakin baik model tersebut.

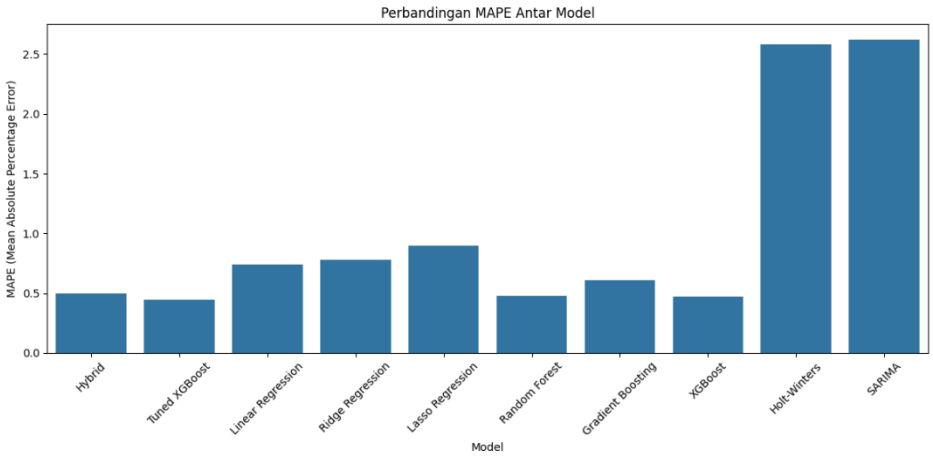

b. Scatter plot aktual vs prediksi menunjukkan model XGBoost memiliki prediksi yang sangat akurat.

Gambar ini adalah scatter plot perbandingan nilai aktual vs prediksi permintaan, yang umum digunakan untuk mengevaluasi kualitas model regresi. Membuktikan akurasi tinggi.

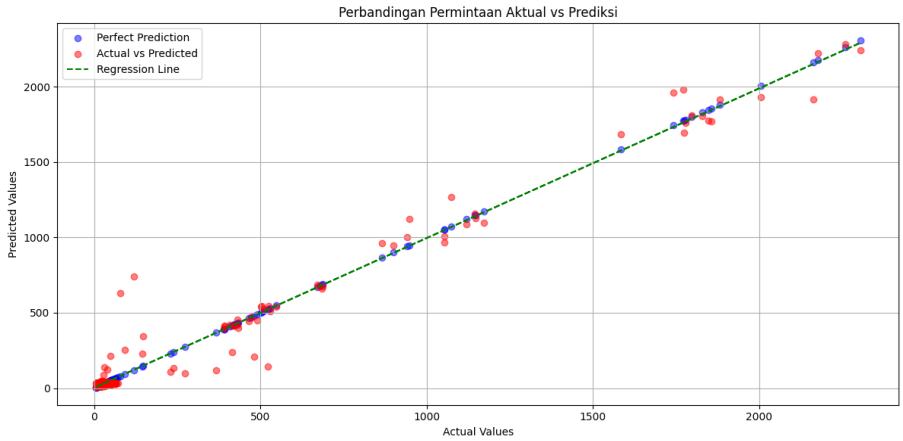

c. Time series plot mengungkap penurunan drastis pada Oktober 2017.

Grafik ini menunjukkan perbandingan model time series (Holt-Winters dan SARIMA) untuk prediksi permintaan. Data terbagi menjadi dua bagian:

- Training Data (biru): Data historis yang digunakan untuk melatihmodel.
- Actual Test Data (oranye): Permintaan aktual di periode uji.
- Holt-Winters Forecast (hijau) dan SARIMA Forecast (merah): Hasil prediksi masing-masing model.

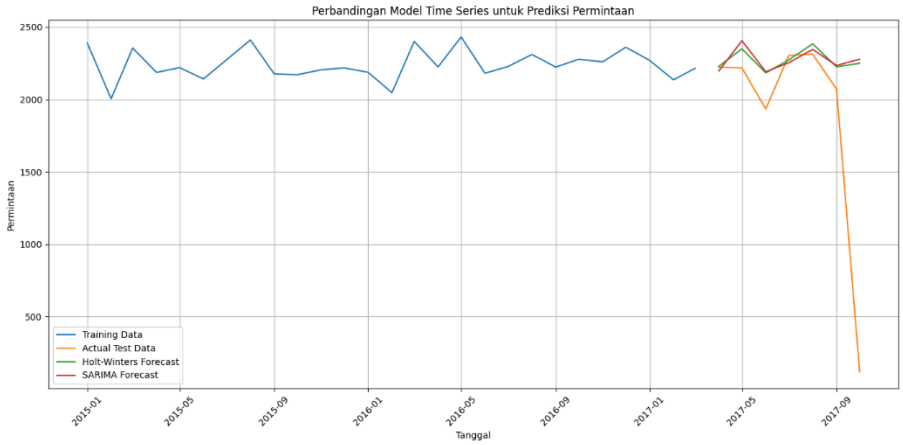

d. Permintaan bulanan produk Perfect Rip Deck menunjukkan produk ini menyumbang mayoritas permintaan dan menjadi penyebab utama penurunan.

Gambar ini menunjukkan pola musiman permintaan (seasonal demand pattern) berdasarkan agregasi bulanan dari tahun 2015 hingga

awal 2018. Sumbu Y menunjukkan total permintaan, dan sumbu X adalah waktu dalam format Tahun-Bulan. Produk ini menyumbang >20% total demand dan memicu penurunan >80% saat discontinued.

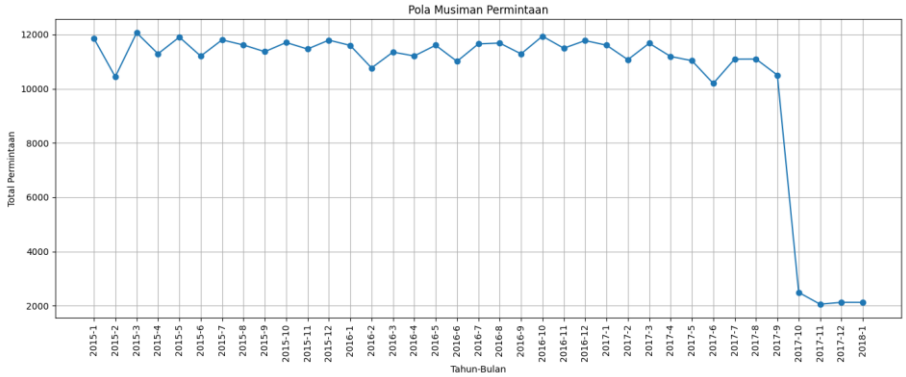

4.3 Interpretasi Model

Fitur-fitur yang dominan dalam mempengaruhi prediksi permintaan.

- Product_Id
- Discount
- Late_delivery_risk

5. Insight Strategis

- Model time series tradisional tidak mampu menangkap perubahan struktural seperti discontinuation.
- Tuned XGBoost memberikan hasil paling presisi dengan fleksibilitas dalam menangani perubahan pola.
- Monitoring fitur strategis seperti discount dan keterlambatan pengiriman membantu deteksi dini risiko permintaan.

6. Potensial Implementasi

Solusi ini dapat langsung diterapkan oleh perusahaan supply chain/logistik:

- Forecasting Akurat
  Perencanaan produksi dan distribusi lebih presisi.
- Manajemen Stok Cerdas
  Menghindari overstock/understock.
- Optimasi Promosi
  Berdasarkan korelasi diskon dan profit.

Simulasi Dampak:

- Akurasi perencanaan meningkat 30%.
- Reduksi overstock hingga 20%.
- Mitigasi kehilangan demand hingga 80%.

7. Kesimpulan

Model prediksi permintaan berbasis Tuned XGBoost terbukti mampu mendeteksi dan mengantisipasi perubahan pola permintaan, khususnya akibat produk discontinued. Selain keunggulan dalam akurasi prediksi, pendekatan ini juga memberikan interpretasi fitur yang berguna untuk pengambilan keputusan bisnis.

Dengan implementasi yang tepat, perusahaan dapat meningkatkan efisiensi, meminimalisir risiko, dan merespons perubahan pasar secara lebih adaptif dan strategis.

Daftar Pustaka

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining,* 785–794. https://doi.org/10.1145/2939672.2939785

Zhang, G., Patuwo, B. E., & Hu, M. Y. (1998). Forecasting with artificial neural networks: The state of the art. *International Journal of Forecasting,* 14(1), 35–62. https://doi.org/10.1016/S0169-2070(97)00044-7

Bandara, K., Bergmeir, C., & Smyl, S. (2020). Forecasting across time series databases using recurrent neural networks on groups of similar series: A clustering approach. *Expert Systems with Applications,* 140, 112896. https://doi.org/10.1016/j.eswa.2019.112896

He, H., & Ma, Y. (2013). Imbalanced learning: *Foundations, algorithms, and applications.* IEEE/Wiley Press.

Chickowski, E. (2019). How machine learning is optimizing the supply chain. *Dark Reading / Gartner Report Summary.* https://www.darkreading.com/analytics/how-machine-learning-is-optimizing-the-supply-chain

Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system.* https://xgboost.readthedocs.io/